




Data Science コース

機械学習入門



講師の紹介



Gruszka Martyna (マルティナ)

専門分野：自然言語処理



城間 颯

専門分野：自然言語処理



淵上 皓一

専門分野：機械学習

Data Scienceコースの内容紹介



Pandasの基本操作

- データの前処理
- データの可視化



Scikit-learnの基礎

- 機械学習の基礎
- 回帰モデルの作成






はじめての 大規模言語モデル

- LLMの基礎
- 文章生成の仕組み

回帰・Linear Regressionとは？

データと予測との残差を最小化するモデルのパラメータを求めます



回帰・Linear Regressionとは？

データと予測との残差を最小化するモデルのパラメータを求めます


モデルとは、説明変数 x から 目的変数 y を予測する数式

MLモデル

$$y = ax + b$$


残差とは、モデルで予測した
目的変数 $\hat{y}$ と実測値 y の差

$$y - \hat{y}$$



回帰・Linear Regressionとは？

データと予測との残差を最小化するモデルのパラメータを求めます



単回帰

説明変数が**ただ1つ**

重回帰

説明変数が**2つ以上**

事例

(x_i, y_i)

[○ ○]

パラメータ

(a, b)

$((x_{i,1}, x_{i,2}, \dots, x_{i,d}), y_i)$

[[○ ○ ... ○] ○]
← d →

$\begin{bmatrix} w_1 \\ w_2 \\ \vdots \\ w_d \end{bmatrix}$

回帰・Linear Regressionとは？

データと予測との残差を最小化するモデルのパラメータを求めます


モデルとは、説明変数 x から 目的変数 y を予測する数式

MLモデル

$$y = ax + b$$


残差とは、モデルで予測した
目的変数 $\hat{y}$ と実測値 y の差

$$y - \hat{y}$$



機械学習のWorkFlow

② 学習



データの前処理

データの準備



	total_bill	sex	smoker	day	time	size	tip
0	16.99	Female	No	Sun	Dinner	2	1.01
1	10.34	Male	No	Sun	Dinner	3	1.66
2	21.01	Male	No	Sun	Dinner	3	3.50
3	23.68	Male	No	Sun	Dinner	2	3.31
4	24.59	Female	No	Sun	Dinner	4	3.61


モデルは数値しか扱えないため、非数値のすべてのエントリを数値に変換する必要がある。

データとは、事例 (x, y) の集合

目的変数 y (tip)を予測したい

→ **説明変数 x** を目的変数 y と
相関がありそうなものに設定

相関係数の可視化



データの事前処理

データの準備



	total_bill	sex	smoker	day	time	size	tip
0	16.99	Female	No	Sun	Dinner	2	1.01
1	10.34	Male	No	Sun	Dinner	3	1.66
2	21.01	Male	No	Sun	Dinner	3	3.50
3	23.68	Male	No	Sun	Dinner	2	3.31
4	24.59	Female	No	Sun	Dinner	4	3.61

モデルは数値しか扱えないため、非数値のすべてのエントリを数値に変換する必要がある。

欠損値への対応

- 削除
- 平均値で補う
- などなど

Data columns (total 7 columns):				
#	Column	Non-Null Count		Dtype
---	-----	-----		-----
0	total_bill	244	non-null	float64
1	sex	244	non-null	object
2	smoker	234	non-null	object
3	day	244	non-null	object
4	time	244	non-null	object
5	size	244	non-null	int64
6	tip	244	non-null	float64

smoker		
No	→	0 146
Yes	→	1 88

Codingセッション

Notebook 1を参考にしながら、Notebook 2を
解ける範囲まで進めてみてください

質問ある方は直接声かけるか、チャットやSlackチャンネルで
DMなどでお気軽に質問してください 

@Gruszka_Martyna, @Shiroma_Hayate, @K Fuchigami116

最後に

Data Scienceコースにご参加いただき、ありがとうございました！

楽しんでいただけましたか？機械学習への関心は高まりましたか？

間に合わなかったところは、時間があるときにぜひやってみてください！
数日後にメールで答えを送りますので、
チェックをお願いします 😊





またお会いできるのを
楽しみにしています！

Hugkun体験会 第3回開催 8月8日（金曜日）